编译器设计专题实验五：

语义分析框架

计算机 2101 田濡豪 2203113234

1 实验内容（必做）

1.1 实验要求（用户需求）

目标：SLR 引导的语义分析框架实现

输入：-SLR(1)分析表（实验四输出）嵌入语义动作的文法规则（文件或硬编码）

- Token 流（实验二输出）

输出：- 抽象语法树（AST）的可视化表示，符号表（变量名、类型、作用域），语义错误报告（如类型错误）

要求：在 SLR(1)语法分析的基础上，集成语义动作，构建抽象语法树（AST）并维护符号表，完成类型检查和初步语义验证。

额外信息：编译器只针对一个特定的文法。

```
P -> D' S' # 程序入口
D' -> epsilon | D' D; # 声明表
D -> T d | T d[i] | T d(A'){D' S'} # 单个声明
T -> int | float | void; # 类型
A' -> epsilon | A' A; # 形参
A -> T d | T d[] | T d(T) # 单个形参
S' -> S | S' ; S # 语句表
S -> d = E | d[E] = E | if (B) S | if (B) S else S | while (B)
S | return E | {S'} | d(R') # 语句
E -> num | flo | d | d[E] | E + E | E * E | (E) | d(R') # 常规
算数表达式
B -> E r E | E # 布尔表达式
R' -> epsilon | R' R, # 实参表
R -> E | d[] | d() # 单个实参
```

1.2 实验设计

1.2.1 需求分析

在先前实验中已经完成了原始程序到 token 流的转换器，以及从 CFG 文法到 SLR(1) 分析表的生成。现在需要在次基础上实现语义分析功能。因此首先需要定义语义动作的结构。

对模型部分：

- 增加面向 CFG 的语义规则模型：

  - 在语法符号（终结符/非终结符）层面，预设计/定义一系列符号属性。准备的属性集合应该涵盖实验给出测试文法中所有可能的符号属性。

  - 在产生式层面，应该预定义一系列语义动作函数。根据每个 AST 节点的类型和属性，语义动作函数可以执行不同的操作。比如，对于一个变量声明产生式，可以有一个语义动作函数来处理变量的类型检查和符号表的更新。

  - 在设计语义规则时，应当尽量保证（本设计要求必须保证）所有属性都是综合属性，即每个属性只依赖自身及其子节点的属性，而不依赖于父节点或兄弟节点的属性。否则 AST 的构建和遍历将会变得复杂，且难以维护。

- 增加符号及符号表模型：

  - 语义分析的最终输出是一个符号表，其是包含了所有符号的符合数据结构。符号表应该支持轻松的增删改查并能够帮助发现重复定义等错误。

  - 符号表的每个表项都是一个符号对象，其中所有的符号都包含一些共有属性，例如名称和类型等。除此之外，符号也可以根据符号类型包含其自定义属性。例如，函数拥有参数列表、返回值类型等属性。而数组（多维）则拥有维度个数、每个维度的长度等属性。符号在设计时也应该支持语义检查。比如某个声明产生式 D -> T id 在进行语义分析时，发现 T 的类型是 int，而 id 的类型是 float，则应该报错。

- 增加 AST 模型：

  - 抽象语法树（AST）是语义分析的核心数据结构。每个 AST 节点用一个 CFG 文法符号标识，同时根据产生式和父节点/子节点关系构建树结构。AST 树模型在设计时就应当支持先根/后跟遍历、按顺序访问子节点（即一个节点符号对应的某个产生式）等操作。

  - 每个抽象语法树节点除了树形结构的基本连接关系和文法符号表示外，应当保存所有相关的符号属性。比如一个变量声明节点应该保存变量名、类型等属性，而一个函数调用节点应该保存函数名、实参列表等属性。同时，如果该节点在符号表中有对应的符号对象，应当使用某种方式和符号表中的符号对象关联起来，毕竟符号表的最重要作用就是方便中间代码生成遍历 AST 时查找符号。

对实现部分：

- 增加基于多栈 PDA 的 SLR(1)-AST 构建工具：

  - 这个工具也是语法分析工具，其会一边构建 AST 树一边进行语法分析。同时，它也几乎不具备语义分析功能。只是在 AST 树的节点上标明节点类型，方便后续的语义分析和中间代码生成。

- 增加语义分析器：

  - 假设 AST 树生成无误，就可以直接使用 AST 树进行语义分析。语义分析器需要遍历 AST 树，并根据每个节点的类型和属性执行相应的语义动作函数。它还需要维护符号表，并在遇到语义错误时生成错误报告。

- 语法/语义分析可视化工具：

  - 根据实验要求，需要提供一个可视化工具来展示 AST 树和符号表。这个工具可以帮助用户理解语法分析和语义分析的过程，并且能够直观地查看符号表中的内容。

所以整体语法分析-语义分析的过程是

1. 加载相关数据

2. 使用 SLR(1)-AST 构建工具解析 token 流，生成 AST 树（同时进行语法分析），其中语义信息除了节点类型外留空。

3. 使用语义分析器第二遍访问 AST 树，填充节点的语义信息，并维护符号表和作用域等相关信息。语义分析器还需要检查语义错误并生成错误报告。

4. 汇总各种数据结构并进行可视化展示。

1.2.2 关键数据模型设计

1.2.2.1 目标 CFG 文法的增广语义规则设计

1.2.2.1.1 属性设计

宗旨：

1. 所有属性都应当是综合属性，即每个属性只依赖于自身及其子节点的属性，而不依赖于父节点或兄弟节点的属性。
2. 属性设计应当尽可能分担语义分析和中间代码生成的工作量，避免重复计算。例如，如果能通过增加属性减少访问 AST 树节点的次数，则应当增加属性。理

想情况下，语义分析只需要遍历一次 AST 树即可完成所有工作，每当访问到一个节点时，所有需要的信息都已经准备好了，中间代码生成同理。

为了清晰和可读性，一般情况下我们约定属性名和配置文件中规定的别名一致。

首先从始终位于 AST 树最底端的终结符开始。终结符的属性比较简单，只分为有具体值的终结符和没有具体值的终结符，前者多一个 value 属性，后者只有 node_type 属性。node_type 属性同时也标明了 AST 树节点的类型。所有终结符属性显然符合继承属性要求。

、+、=、[*、*]*、*(*、*)*、*{*、*}*、*;*、*,*、*if*、*else*、*while*、*return*、*int*、*float*、*void:*

- 属性 1：node_type，词法分析类别。凡是词法分析中只有类型名而 token 流中不涉及具体值的终结符都可以使用该属性。比如 if、else、while 等。

num、*flo*、*d*、*r:*

- 属性 1：node_type，值为一个字符串，就是其词法分析类别，示数据类型（int、float、void 等），当遇到表达式时就可以用于语法检查了。
- 属性 2：value，别名 value，值为一个字符串（由于不知道代码生成后端的具体表示方式，因此这里使用字符串表示，后端可以根据需要转换为具体类型）。比如 num 的值为数字字符串，flo 的值为浮点数字符串，d 的值为变量名字符串，r 的值为布尔运算（如<，==）字符串。

设计非终结符的属性：

P——程序入口:

程序入口节点是 AST 树的根节点，表示整个程序的起点。它无需往上传递任何属性。对它的操作也只需要通过访问子节点来完成。

- 属性 1：node_type，固定为字符串 PROGRAM，表示这是一个程序入口节点。
- 属性 2：scope_id，别名 scope_id，值为一个整数，表示该程序入口的作用域编号。这个属性标识了该程序入口的作用域，便于在符号表中查找和管理符号。

特别约定：scope_id 属性值为-1 时代表尚未分配作用域编号，最外层的作用域编号为 0。

依赖分析：不需要分析。

结构体示例：

```
struct ProgramNode {
    std::string node_type = "PROGRAM"; // 固定值
    int scope_id = 0; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

D'——声明表:

声明表是一个声明集合，并且能够确定所有其中的声明作用域都是相同的。只有到了声明表阶段，才会开始真正的符号表和作用域的建立。

- 属性 1：node_type，固定为字符串 DECL_LIST，表示这是一个声明表节点。
- 属性 2：decl_count，别名 decl_count，值为一个整数，表示声明的个数。
- 属性 3：declarations，别名 declarations，是一个向量，包含每个声明节声明节点的定义。这个属性用于向上传递该声明部分所包含的所有声明，以建立每个声明的作用域。
- 属性 4：scope_id，别名 scope_id，值为一个整数，表示该声明表的作用域编号。这个属性标识了该声明表的作用域，便于在符号表中查找和管理符号。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct DeclListNode {
    std::string node_type = "DECL_LIST"; // 固定值
    int decl_count = 0; // 声明个数
    std::vector<std::shared_ptr<DeclNode>> declarations; // 声明节点列表
    int scope_id = -1;
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

D——声明:

声明节点需要提供类型、变量名、数组长度、形参表等信息。

- 属性 1：node_type，固定前缀为 DECL_，表示这是一个声明节点。后缀根据具体的声明类型而定，比如 DECL_VAR、DECL_ARRAY、DECL_FUNC 等。
    1. 对于变量声明，使用 DECL_VAR，表示这是一个变量声明节点。
    2. 对于数组声明，使用 DECL_ARRAY，表示这是一个数组声明节点。
    3. 对于函数声明，使用 DECL_FUNC，表示这是一个函数声明节点。
- 属性 2：data_type，直接由 T 决定，即变量类型或函数返回值。
- 属性 3：var_name，别名 var_name，值为一个字符串，表示该声明的变量名（如果是数组或函数，则为对应的名称）。
- 属性 4：array_length，别名 array_length，值为一个整数，表示该数组的长度（如果是数组声明）。如果不是数组声明，则该属性无效。
- 属性 5：arg_list，别名 arg_list，是一个 ArgListNode 对象，表示该函数的形参表（如果是函数声明）。如果不是函数声明，则该属性无效。

- 属性 6：function_sub_scope，别名 function_sub_scope，是一个整数，表示该函数声明的子作用域编号（如果是函数声明）。如果不是函数声明，则该属性无效。
- 属性 7：scope_id，别名 scope_id，值为一个整数，表示该声明的作用域编号。这个属性标识了该声明的作用域，便于在符号表中查找和管理符号。

依赖分析：node_type 依赖于自身的属性，data_type、var_name、array_length、arg_list 依赖于子节点的属性。显然一个变量/函数/数组在使用前必须先声明，因此语法正确的情况下其一定在符号表中有对应的符号对象。因此符合继承属性要求。

结构体示例：

```
struct DeclNode {
    std::string node_type = ""; // 声明类型，前缀为"DECL_"
    std::string data_type = ""; // 数据类型，可能是"int"、"float"等
    std::string var_name = ""; // 变量名
    std::optional<int> array_length = 0; // 数组长度，仅在声明是数组时有效
    std::optional<ArgListNode> arg_list; // 形参表，仅在声明是函数时有效
    std::optional<int> function_sub_scope = 0; // 函数子作用域编号，仅在声明是函数时有效
    int scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

T——类型名:

- 属性 1：node_type，固定为字符串 TYPE，表示这是一个类型名节点。
- 属性 2：data_type，别名 data_type，值为一个字符串，表示该类型的具体数据类型（num-对应 int、flo-对应 float 等）。
    1. 对各个基本类型，直接使用其词法分析类别作为 data_type 的值，比如 INT，FLOAT、VOID 等。

依赖分析：仅依赖自身的属性，因此符合继承属性要求。

结构体示例：

```
struct TypeNode {
    std::string node_type = "TYPE"; // 固定值
    std::string data_type = ""; // 数据类型，可能是"int"、"float"等
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

A'——形参表:

需要提供形参的个数、每个形参的类型、变量名、数据类型等信息。

- 属性 1：node_type，固定为字符串 ARG_LIST，表示这是一个形参表节点。
- 属性 2：arg_count，别名 arg_count，值为一个整数，表示形参的个数。
- 属性 3：arg_info，别名 arg_info，是一个向量，包含每个形参的详细信息。每个形参信息是一个 ArgNode 对象，包含了形参的类型、数据类型、变量名等。用于语义检查和语义分析形参声明时的类型检查等。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct ArgListNode {
    std::string node_type = "ARG_LIST"; // 固定值
    int arg_count = 0; // 形参个数
    std::vector<shared_ptr<ArgNode>> arg_info; // 形参信息列表
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

A——形参:

形参需要提供数据类型、传入的变量类型以及要在函数中用到的变量名等信息。

- 属性 1：node_type，固定前缀为 ARG_，表示这是一个形参节点。后缀根据具体的形参类型而定，比如 ARG_VAR、ARG_ARRAY 等。
    1. 对于常规变量，使用 ARG_VAR，表示这是一个变量形参节点。
    2. 对于数组元素，使用 ARG_ARRAY，表示这是一个数组元素形参节点。
    3. 对于函数调用，使用 ARG_FUNC，表示这是一个函数调用形参节点。
- 属性 2：data_type，别名 data_type，值为一个字符串，表示该形参的数据类型（num-对应 int、flo-对应 float 等）。这个类型是由 T 节点提供的。
- 属性 3：var_name，别名 var_name，值为一个字符串，表示该形参的变量名（如果是数组或函数调用，则为对应的名称）。

依赖分析：node_type 依赖于自身的属性，data_type 和 var_name 依赖于子节点的属性。显然一个变量/函数/数组在使用前必须先声明，因此语法正确的情况下其一定在符号表中有对应的符号对象。因此符合继承属性要求。

结构体示例：

```
struct ArgNode {
    std::string node_type = ""; // 形参类型，前缀为"ARG_"
    std::string data_type = ""; // 数据类型，可能是"int"、"float"等
    std::string var_name = ""; // 变量名
```

```
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

S'——语句表:

语句表是一个非声明语句语句集合，并且能够确定所有其中的语句作用域都是相同的。

- 属性 1：node_type，固定为字符串 STAT_LIST，表示这是一个语句表节点。
- 属性 2：scope_id，别名 scope_id，值为一个整数，表示该语句表的作用域编号。这个属性标识了该语句表的作用域，便于在符号表中查找和管理符号。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct StatListNode {
    std::string node_type = "STAT_LIST"; // 固定值
    int scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

S——语句:

语句节点需要提供：

1. 节点类型（语句类型），方便语义分析和中间代码生成调用合适的处理函数。
2. 语句的变量依赖列表。这个列表包含该节点及其所有子节点所依赖的变量名列表。这个属性会层层向上从传递并增长，直到 S'语句节点。这样就能确定一个作用域内所有需要的变量名。

- 属性 1：node_type，固定前缀为 STAT_，表示这是一个语句节点。后缀根据具体的语句类型而定.
    1. 对赋值语句，使用 STAT_ASSIGN，表示这是一个赋值语句节点。
    2. 对数组元素赋值语句，使用 STAT_ARRAY_ASSIGN，表示这是一个数组元素赋值语句节点。
    3. 对 if 语句，使用 STAT_IF，表示这是一个 if 语句节点。
    4. 对 if-else 语句，使用 STAT_IF_ELSE，表示这是一个 if-else 语句节点。
    5. 对 while 语句，使用 STAT_WHILE，表示这是一个 while 语句节点。
    6. 对 return 语句，使用 STAT_RETURN，表示这是一个 return 语句节点。
    7. 对复合语句（即{S'}），使用 STAT_COMPOUND，表示这是一个复合语句节点。

8. 对函数调用语句（即 d(R')），使用 STAT_FUNC_CALL，表示这是一个函数调用语句节点。

- 属性：scope_id，别名 scope_id，值为一个整数，表示该语句的作用域编号。这个属性标识了该语句的作用域，便于在符号表中查找和管理符号。

依赖分析：node_type 依赖于自身的属性，显然一个变量/函数/数组在使用前必须先声明，因此语法正确的情况下其一定在符号表中有对应的符号对象。因此符合继承属性要求。

结构体示例：

```
struct StatNode {
    std::string node_type = ""; // 语句类型，前缀为"STAT_"
    int scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

E——表达式运算结果:

表达式运算结果包含多个候选式，因此应该为语义分析和中间代码生成提供足够的信息，比如通过节点类别指示应该调用哪个语义动作函数，以及表达式的计算结果等。

- 属性 1：node_type，固定前缀为 EXPR_，表示这是一个表达式节点。后缀根据具体的表达式类型而定，比如 EXPR_NUM、EXPR_VAR 等。
    1. 对直接常量，使用 EXPR_CONST，表示这是一个常量表达式节点。
    2. 对常规变量，使用 EXPR_VAR，表示这是一个变量表达式节点。
    3. 对数组元素，使用 EXPR_ARRAY，表示这是一个数组元素表达式节点。
    4. 对函数调用，使用 EXPR_FUNC，表示这是一个函数调用表达式节点。
    5. 对算术运算，使用 EXPR_ARITH_NOCONST，表示这是一个算术运算表达式节点并且值不固定。如果表达式两侧都是常量，则化简为 EXPR_CONST。
    6. 对括号表达式，使用 EXPR_PAREN_NOCONST，表示这是一个括号表达式节点。同样，如果括号内的表达式是常量，则化简为 EXPR_CONST。
- 属性 2：data_type，别名 data_type，值为一个字符串，表示该表达式的计算结果的数据类型（num-对应 int、flo-对应 float 等）。
    1. 对于常量表达式，直接使用其词法分析类别作为 data_type 的值，比如 INT、FLOAT 等。
    2. 对于其他情况，data_type 无效。

- 属性 3：value，别名 value，值为一个字符串（由于不知道代码生成后端的具体表示方式，因此这里使用字符串表示，后端可以根据需要转换为具体类型）。当且仅当表达式是常量表达式时，value 才有意义。比如 num 的值为数字字符串，flo 的值为浮点数字符串。
- 属性：scope_id，别名 scope_id，值为一个整数，表示该表达式的作用域编号。这个属性标识了该表达式的作用域，便于在符号表中查找和管理符号。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct ExprNode {
    std::string node_type = ""; // 表达式类型，前缀为"EXPR_"
    std::string data_type = ""; // 数据类型，可能是"int"、"float"等
    std::optional<std::string> value = ""; // 表达式值，仅在常量表达式时有效
    // 每个属性都应该设置默认值，以避免未定义行为
    int scope_id = -1; // 作用域编号
};
```

B——布尔表达式:

由于布尔表达式规定了类型必须为布尔，因此一个节点属性可以同时表示布尔表达式的类型和计算结果。

- 属性 1：node_type，固定前缀为 BOOL_，表示这是一个布尔表达式节点。后缀根据具体的布尔表达式类型而定。
    1. 对于布尔运算，使用 BOOL_OP，表示这是一个布尔运算表达式节点。
    2. 对于单个表达式，使用 BOOL_EXPR，表示这是一个单个表达式布尔节点。
- 属性 2：scope_id，别名 scope_id，值为一个整数，表示该布尔表达式的作用域编号。这个属性标识了该布尔表达式的作用域，便于在符号表中查找和管理符号。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct BoolNode {
    std::string node_type = ""; // 布尔表达式类型，前缀为"BOOL_"
    int scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

R——实参:

显然对于语义分析和中间代码生成，在遇到实参的时候，需要知道其是常量还是变量，以及其数据类型等。

- 属性 1：node_type，固定前缀为 RARG_，表示这是一个实参节点。后缀根据具体的实参类型而定，比如 RARG_EXPR、RARG_VAR 等。
    1. 对表达式运算结果，使用 RARG_EXPR，表示这是一个表达式实参节点。
    2. 对数组元素，使用 RARG_ARRAY，表示这是一个数组元素实参节点。
    3. 对函数调用，使用 RARG_FUNC，表示这是一个函数调用实参节点。
- 属性 2：data_type，别名 data_type，值为一个字符串，表示该实参的数据类型（num-对应 int、flo-对应 float 等）。
    1. 对于表达式实参，直接使用其词法分析类别作为 data_type 的值，比如 INT、FLOAT 等。
    2. 对于其他情况，要从符号表中查找对应的符号对象，获取其数据类型。
- 属性 3：var_name，别名 var_name，值为一个字符串，表示该实参的变量名（如果是数组或函数调用，则为对应的名称）。当且仅当实参是变量或数组时，var_name 才有意义。其他情况下中间代码生成器将会访问表达式来进一步获取数据。
- 属性 4：scope_id，别名 scope_id，值为一个整数，表示该实参的作用域编号。这个属性标识了该实参的作用域，便于在符号表中查找和管理符号。

依赖分析：node_type 依赖于自身的属性，data_type 依赖于子节点的属性和符号表。显然一个变量/函数/数组在使用前必须先声明，因此语法正确的情况下其一定在符号表中有对应的符号对象。因此符合继承属性要求。

结构体示例：

```
struct RealArgNode {
    std::string node_type = ""; // 实参类型，前缀为"ARG_"
    std::string data_type = ""; // 数据类型，可能是"int"、"float"等
    std::optional<std::string> var_name = ""; // 变量名，仅在实参是变量或数组时有效
    int scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

R'——实参表:

从语义检查的角度，实参表应当标出实参的个数、每个实参的类型等信息。

- 属性 1：node_type，固定为字符串 RARG_LIST，表示这是一个实参表节点。
- 属性 2：arg_count，别名 arg_count，值为一个整数，表示实参的个数。
- 属性 3：arg_info，别名 arg_info，是一个向量，包含每个实参的详细信息。每个实参信息是一个 ArgNode 对象，包含了实参的类型、数据类型、变量名等。主要用于语义检查，在中间代码生成时还是会通过访问 AST 树节点来获取实参信息。
- 属性 4：scope_id，别名 scope_id，值为一个整数，表示该实参表的作用域编号。这个属性标识了该实参表的作用域，便于在符号表中查找和管理符号。

依赖分析：仅依赖子节点的属性，因此符合继承属性要求。

结构体示例：

```
struct RealArgListNode {
    std::string node_type = "REAL_ARG_LIST"; // 固定值
    int arg_count = 0; // 实参个数
    std::vector<std::shared_ptr<ArgNode>> arg_info; // 实参信息列表
    scope_id = -1; // 作用域编号
    // 每个属性都应该设置默认值，以避免未定义行为
};
```

1.2.2.1.2 符号表设计

符号表由一系列符号对象组成，这些符号有一些共有属性，但同时也有各自的特有属性。符号表的设计应当能够支持符号的增删改查操作，并且能够根据作用域进行分层管理。

首先对每个符号对象的共有属性进行设计：

1. 符号名（symbol_name）：一个字符串，表示符号的名称。
2. 符号类型（symbol_type）：一个枚举类型，表示符号的类型。可以是变量、数组、函数等。
3. 作用域 id（scope_id）：一个整数，表示符号所在的作用域编号。这个编号用于标识符号的作用域，便于在符号表中查找和管理符号。
4. 数据类型（data_type）：一个字符串，表示符号的数据类型（如 int、float 等）。对于函数符号，这个属性表示函数的返回值类型。对于数组符号，这个属性表示数组元素的类型。
5. 抽象内存大小（memory_size）：相对于某个最小单元，如字长，的内存大小。对于函数符号，这*不包含*函数体的内存区间。对于数组符号，这个属性表示数组元素在内存中的起始地址和结束地址。

之后对不同符号对象的特有属性进行设计：
变量符号（VariableSymbol）：
（无特有属性，直接使用共有属性即可。）

数组符号（ArraySymbol）：

1. 数组长度（array_length）：一个整数，表示数组的长度。

函数符号（FunctionSymbol）：

1. 形参列表（arg_list）：一个向量，包含每个形参的详细信息。每个形参信息是一个 ArgNode 对象，包含了形参的类型、数据类型、变量名等。
2. 直接子作用域（direct_child_scope）：一个整数，表示该函数的直接子作用域（也就是函数体的作用域）编号。这个编号用于标识函数的直接子作用域，便于在符号表中查找和管理符号。

其结构体示例如下：

```
struct SymbolEntry {
    std::string symbol_name; // 符号名
    SymbolType symbol_type; // 符号类型
    int scope_id; // 作用域 id
    std::string data_type; // 数据类型
    int memory_size; // 抽象内存大小（相对于最小内存单元）

    // 可选特殊属性
    std::optional<int> array_length; // 数组长度，仅对数组符号有效
    std::optional<std::vector<ArgNode>> arg_list; // 形参列表，仅对函数符号有效
    std::optional<int> direct_child_scope; // 直接子作用域，仅对函数符号有效
};
```

同时，从顶层语义分析要求的角度考虑，定义两个符号相同当且仅当：其名称相同，且其作用域 id 相同。这样就能确保在同一作用域内不会出现同名符号。

因此符号表可以使用一个集合来表示，由于实验有可视化要求，可以将 set 的顺序设置为符号的作用域 id 和符号名的字典序，为后续的可视化提供方便。同时，符号表应该支持添加符号，判断符号是否存在（专用于语义检查）和查找符号（专用于中间代码生成）等操作。

符号表的声明如下：

```
class SymbolTable {
public:
    // 添加符号到符号表
    void addSymbol(const Symbol& symbol);
    // 判断符号是否存在
    bool symbolExists(const std::string& symbol_name, int scope_id) con
st;
    // 查找某个作用域内的某个符号，包括形参
    std::optional<Symbol> findSymbolInScope(const std::string& symbol_n
ame, int scope_id) const;
    // 递归链式查询某个符号在所有作用域中的定义
    std::optional<Symbol> findSymbolInAllScopes(const std::string& symb
ol_name) const;
    // 获取当前作用域的符号列表（注意：如果在函数体内，还要包括函数形参）
    std::vector<Symbol> getAllSymbolsInScope(int scope_id) const;
private:
    // 符号表使用 set 存储符号，按作用域 id 和符号名的字典序排序
    std::set<Symbol> symbols;
};
```

1.2.2.1.3 作用域表设计

作用域表的作用是管理符号的作用域信息，其采用栈来模拟作用域的嵌套关系。每个作用域都有一个唯一的作用域编号（scope_id），并且可以包含多个符号。

作用域表的功能应该包括：

1. 重置/初始化：清空栈等信息，从约定的最外层作用域 0 开始。
2. 进入新作用域：当遇到一个新的作用域时（如函数体等），先通过计数器生成一个新的作用域编号，然后将该编号入栈，并更新作用域之间的父子关系。
3. 退出当前作用域：当离开一个作用域时，将当前作用域编号出栈，并恢复到上一个作用域。
4. 查询直接子作用域：给定一个作用域编号，查询其直接子作用域编号列表。
5. 查询直接父作用域：给定一个作用域编号，查询其直接父作用域编号。
6. 查询当前作用域：获取当前作用域编号，也就是栈顶的作用域编号。

因此，其需要以下基本属性：

1. 作用域 id 计数器（scope_id_counter）：一个整数，表示当前作用域 id 的计数器。每次进入新作用域时递增。

2. 作用域栈（scope_stack）：一个向量，存储当前作用域的编号。每次进入新作用域时将新的作用域编号入栈，每次退出当前作用域时将当前作用域编号出栈。
3. 子作用域表（child_scope_map）：一个映射，键为父作用域编号，值为一个向量，存储该父作用域的直接子作用域编号。用于快速查询直接子作用域。
4. 父作用域表（parent_scope_map）：一个映射，键为子作用域编号，值为父作用域编号。用于快速查询直接父作用域。

因此，作用域表的声明如下：

```
class ScopeTable {
public:
    // 重置作用域表
    void reset();
    // 进入新作用域，返回新的作用域编号
    void enterNewScope();
    // 退出当前作用域，返回上一个作用域编号
    void exitCurrentScope();
    // 查询直接子作用域
    std::vector<int> getDirectChildScopes(int scope_id) const;
    // 查询直接父作用域
    int getDirectParentScope(int scope_id) const;
    // 获取当前作用域编号
    int getCurrentScope() const;
private:
    int scope_id_counter; // 作用域 id 计数器
    std::vector<int> scope_stack; // 作用域栈
    std::unordered_map<int, std::vector<int>> child_scope_map; // 子作用域表
    std::unordered_map<int, int> parent_scope_map; // 父作用域表
};
```

1.2.2.1.4 语义动作函数设计

为了充分利用 C++的多态性，首先约定**上述所有节点类型都是从一个基础结构体 ASTNodeContent 派生而来**。这个基类包含两个纯虚函数：

1. subnode_takein(std::vector<std::shared_ptr<ASTNodeContent>> subnodes)：用于接收子节点，并将其存储在一个向量中。这个函数会在每个具体的节点类中实现，以便于处理不同类型的子节点。使用指针来实现同一个列表中可以存储不同类型的节点。理论上来说，可以完全不依赖这个函数。但是由于树形结构是由 tree.hh 库来管理的，如果每次都去调用其方法访问子节点会增加不必要的耦合和复杂度，因此这个方法的本质是创造一个清晰的子节点缓存，让语

义动作执行完全在 ASTNodeContent 的子类中进行，而不是依赖于 tree.hh 库的接口。

2. semantic_action(int scope_id, std::shared_ptr<SymbolTable> symbol_table, std::shared_ptr<ScopeTable> scope_table)：用于执行语义动作。这个函数会在每个具体的节点类中实现，以便于执行特定的语义检查和中间代码生成。

此外，我们要求节点在构建时必须传入一个 node_type 参数，用于标识节点的类型。这个参数会在构造函数中设置，并且在 subnode_takein 和 semantic_action 函数中使用。这是一定可以做到的，因为产生式一旦确定了，节点类型就已经是固定的了。其中一个特例是 E 的常量折叠情况，在不知道是否可以将表达式折叠为常量时，可以先创建一个 EXPR_NOCONST 类型的节点，等到语义分析阶段再进行常量折叠。（理论上如果设计完善，即使不折叠也可以正常生成中间代码）

最后，由于有可视化要求，所有的节点类型都应该能够转换为一个字符串表示形式，以便于在可视化工具中展示。因此要能将每个节点类型转换为一个字符串，表示其中的信息

因此，ASTNodeContent 的定义如下：

```
struct ASTNodeContent {
    std::string node_type; // 节点类型，用于标识节点的类型
    std::vector<std::shared_ptr<ASTNodeContent>> subnodes; // 子节点列表
    // 接收子节点
    virtual void subnode_takein(std::vector<std::shared_ptr<ASTNodeCont
ent>> subnodes) = 0;
    // 执行语义动作
    virtual void semantic_action(int scope_id, std::shared_ptr<SymbolTa
ble> symbol_table, std::shared_ptr<ScopeTable> scope_table) = 0;
    // 将节点转换为字符串表示形式
    virtual std::string to_string() const = 0;
    virtual ~ASTNodeContent() = default; // 虚析构函数，确保派生类正确析构
};
```

值得注意的是该定义并不包含树形结构的基本要素，如父节点指针等。这是因为我决定把维护树形结构的复杂度分担到一个开源 C++树形库 tree.hh 中，减少不必要的错误和复杂度。tree.hh 库提供了树形结构的基本操作，如添加子节点、删除子节点等，因此可以直接使用它来管理 AST 树的结构。

接下来开始对每个节点的每个细分类型的语义动作函数进行设计，此处只给出自然语言描述。

此处的语义动作指的是回溯时执行的语义动作函数，在进入该节点时的作用域移入等操作会在后文的作用域管理部分进行设计。也就是，执行语义动作函数时所有子节点的作用域已经确定了。

P -> D' S' # 程序入口

D' -> epsilon | D' D; # 声明表

D -> T d | T d[num] | T d(A'){D' S'} # 单个声明，分别是声明变量、数组和函数

T -> int | float | void # 类型

A' -> epsilon | A' A; # 形参表

A -> T d | T d[] | T d(T) # 单个形参，形参类型分别是基本类型、数组和函数

S' -> S | S' ; S # 语句表

S -> d = E | d[E] = E | if (B) S | if (B) S else S | while (B) S | return E | {S'} | d(R') # 语句

E -> num | flo | d | d[E] | E + E | E * E | (E) | d(R') # 常规算数表达式

B -> E r E | E # 布尔表达式

R' -> epsilon | R' R, # 实参表

R -> E | d[] | d() # 单个实参，分别是表达式运算结果、数组和函数调用

P——程序:

当开始处理 P 的语义动作时，整个语义分析已经几乎完成了。此刻 P 应该检查一些属于整个最外层程序的特殊属性。

1. 确认是否有主函数（main 函数，且位于作用域 0），如果没有则抛出语义错误，表示缺少主函数。
2. 确认主函数的返回类型是否为 int，如果不是则抛出语义错误，表示主函数返回类型错误。
3. 确认主函数的形参个数是否为 0，如果不是则抛出语义错误，表示主函数形参个数错误。

D'——声明表:

声明表实际上也是一个容器，包含了所有的声明，因此无需提供语义动作函数。它的作用是将所有声明节点收集起来，便于后续的语义分析和中间代码生成。

D——声明:

声明节点是真正将声明信息传递给符号表的地方，因此需要提供语义动作函数。其语义动作函数的作用是将当前声明的信息添加到符号表中，并进行必要的语义检查。

1. 从子节点 T 获取数据类型（data_type）。
2. 检查数据类型是否是当前 node_type 可声明的类型，比如不允许有 void 类型的数组。

3. 从子节点 d 获取变量名（var_name）。
4. 如果是普通变量声明（T d），则创建一个变量符号对象，并添加到符号表中。
5. 如果是数组声明（T d[num]），则创建一个数组符号对象，并添加到符号表中，同时设置数组长度。其内存大小由数组长度和数据类型决定。
6. 如果是函数声明（T d(A'){D' S'}），则创建一个函数符号对象，并添加到符号表中，同时设置形参列表和直接子作用域编号。随后，将所有的形参添加到符号表中，并设置作用域编号为当前函数的作用域编号，其抽线内存大小均为一个内存地址的大小。比如如果实参最终传入了一个数组，则生成代码时要通过数组的首地址来访问实参在内存中的位置。
7. 如果上述添加时发现符号表中已经存在同名符号，则抛出语义错误，表示重复声明。

T——类型名:

将直接子节点的 node_type 作为数据类型（data_type）传递给声明节点的语义动作函数。

A'——形参表:

A' -> epsilon | A' A;

形参表只需维护形参的个数和详细信息，因此其语义动作函数的作用是将所有形参的信息收集起来，届时提供给函数声明的语义动作函数。

1. 如果没有子节点，对应 A' -> epsilon，则初始化形参个数为 0，形参信息为空。
2. 如果有子节点，则将子节点 A'的形参信息添加到形参表中，并设置形参个数为相同。然后将子节点 A 的形参信息添加到形参表中，并递增形参个数。

A——形参:

1. 从子节点 T 获取数据类型（data_type）。
2. 从子节点 d 获取变量名（var_name）。
3. 检查数据类型是否是当前 node_type 可声明的类型，比如不允许有 void 类型的常规变量/数组形参。

S'——语句表:

语句表实际上也是一个容器，包含了所有的语句，因此无需提供语义动作函数。它的作用是将所有语句节点收集起来，便于后续的语义分析和中间代码生成。

S——语句:

在根据 node_type 确定语句类型后，语义动作函数的作用是将所有语句的信息收集起来，便于后续的语义分析和中间代码生成。

分情况讨论：

1. 如果类型是 STAT_ASSIGN
    - 从子节点获取变量名
    - 检查变量名是否在符号表中存在，如果不存在则抛出语义错误，表示未声明的变量。如果在，取到其数据类型。
    - 检查符号类型是否与语句类型相一致，比如不能给函数或数组赋值。
    - 检查数据类型是否与表达式的计算结果数据类型相一致，如果不一致则抛出语义错误，表示类型不匹配。
2. 如果类型是 STAT_ARRAY_ASSIGN
    - 从子节点获取变量名和数组下标表达式。
    - 检查变量名是否在符号表中存在，如果不存在则抛出语义错误，表示未声明的数组。如果在，取到其数据类型。
    - 检查符号类型是否为数组类型，如果不是则抛出语义错误，表示类型不匹配。
    - 检查数组下标表达式的计算结果数据类型是否为整数，如果不是则抛出语义错误，表示下标类型不匹配。
    - 检查数据类型是否与表达式的计算结果数据类型相一致，如果不一致则抛出语义错误，表示类型不匹配。
3. 如果类型是 STAT_IF
    - 从子节点获取布尔表达式（事实上，只要确认有这个布尔表达式就行了，因为布尔表达式也会检查其是否能进行布尔运算）
4. 如果类型是 STAT_IF_ELSE
    - 从子节点获取布尔表达式和两个语句表。结束。
5. 如果类型是 STAT_WHILE
    - 从子节点获取布尔表达式，同上。
6. 如果类型是 STAT_RETURN
    - 从子节点获取返回值表达式。
    - 在作用域表中查找直接父作用域 ID。
    - 如果父作用域 ID 为-1，则抛出语义错误，表示 return 语句只能在函数体内使用。
    - 在符号表中查找直接子作用域 ID 对应的函数符号对象。

- 检查函数符号对象的返回值类型是否与返回值表达式的计算结果数据类型相一致，如果不一致则抛出语义错误，表示类型不匹配。

7. 如果类型是 STAT_COMPOUND
    - 无需处理，因为复合语句的作用域已经在进入该语句时设置好了。
8. 如果类型是 STAT_FUNC_CALL
    - 从子节点获取函数名和实参表。
    - 在符号表中查找函数符号对象，如果不存在则抛出语义错误，表示未声明的函数。
    - 检查函数符号对象的形参个数是否与实参表中的实参个数相一致，如果不一致则抛出语义错误，表示实参个数不匹配。
    - 检查每个实参的类型是否与形参的类型相一致，如果不一致则抛出语义错误，表示实参类型不匹配。

E——表达式:

还是分情况讨论：

1. 如果类型是 EXPR_CONST
    - 从子节点获取常量值和数据类型。
    - 将 data_type 和 value 设置到当前节点的属性中。
2. 如果类型是 EXPR_VAR
    - 从子节点获取变量名。
    - 在符号表中查找变量符号对象，如果不存在则抛出语义错误，表示未声明的变量。
    - 将 data_type 设置为符号对象的数据类型。
3. 如果类型是 EXPR_ARRAY
    - 从子节点获取数组名和下标表达式。
    - 在符号表中查找数组符号对象，如果不存在则抛出语义错误，表示未声明的数组。
    - 检查下标表达式的计算结果数据类型是否为整数，如果不是则抛出语义错误，表示下标类型不匹配。
    - 将 data_type 设置为数组元素的数据类型。
4. 如果类型是 EXPR_FUNC（和 S 的处理方式类似）

- 从子节点获取函数名和实参表。
- 在符号表中查找函数符号对象，如果不存在则抛出语义错误，表示未声明的函数。
- 检查函数符号对象的形参个数是否与实参表中的实参个数相一致，如果不一致则抛出语义错误，表示实参个数不匹配。
- 检查每个实参的类型是否与形参的类型相一致，如果不一致则抛出语义错误，表示实参类型不匹配。
- 将 data_type 设置为函数符号对象的返回值类型。

5. 如果类型是 EXPR_ARITH_NOCONST（注意：此时需要尝试常量折叠）
    - 从子节点获取左侧和右侧表达式。
    - 检查左右侧表达式结果类型是否一致，如果不一致则抛出语义错误，表示类型不匹配。
    - 检查左右侧表达式的计算结果数据类型是否为整数或浮点数，如果不是则抛出语义错误，因为没法计算 void 类型的表达式。
    - 如果左右侧表达式都是常量，则进行常量折叠，计算结果并将 data_type 和 value 设置到当前节点的属性中。同时，修改当前节点的 node_type 为 EXPR_CONST。
    - 如果有任意一个表达式不是常量，则将 data_type 设置为左右侧表达式的计算结果数据类型，并将 node_type 保持为 EXPR_ARITH_NOCONST。
6. 如果类型是 EXPR_PAREN_NOCONST
    - 从子节点获取括号内的表达式。
    - 检查其计算结果是否为常量，如果是，则进行常量折叠，计算结果并将 data_type 和 value 设置到当前节点的属性中。同时，修改当前节点的 node_type 为 EXPR_CONST。
    - 如果不是常量，则将 data_type 设置为括号内表达式的计算结果数据类型，并将 node_type 保持为 EXPR_PAREN_NOCONST。

B——布尔表达式:

1. 如果是 BOOL_EXPR，获取子节点的表达式类型值。检查其是否为整数。如果不是整数，则抛出语义错误，表示布尔表达式必须是整数类型。
2. 如果是 BOOL_OP，获取子节点的左侧和右侧表达式。检查它们计算结果是否均为整数。

R'——实参表:

实参表的语义动作函数的作用是将所有实参的信息收集起来，届时提供给函数调用的语义动作函数。

1. 如果没有子节点，对应 R' -> epsilon，则初始化实参个数为 0，实参信息为空。
2. 如果有子节点，则将子节点 R'的实参信息添加到实参表中，并设置实参个数为相同。然后将子节点 R 的实参信息添加到实参表中，并递增实参个数。

R——实参:

1. 如果类型是 ARG_EXPR
    - 从子节点获取表达式。
    - 将 data_type 设置为表达式的计算结果数据类型。
2. 如果是 ARG_ARRAY
    - 从子节点获取数组名和下标表达式。
    - 在符号表中查找数组符号对象，如果不存在则抛出语义错误，表示未声明的数组。
    - 将 data_type 设置为数组元素的数据类型。
3. 如果是 ARG_FUNC
    - 从子节点获取函数名和实参表。
    - 在符号表中查找函数符号对象，如果不存在则抛出语义错误，表示未声明的函数。
    - 将 data_type 设置为函数符号对象的返回值类型。

1.2.2.1.5 作用域管理设计

作用域管理按照几条简单的基本规则实现：

1. 从根节点 P 开始时，重置作用域表和符号表，设置当前作用域为 0。
2. 当当前节点是函数声明节点 D 时，且下一个要进入的节点是 D'（声明表），则进入新作用域，设置当前作用域为函数的直接子作用域编号，并将函数符号对象添加到符号表中。从 D'退出后，*不要退出当前作用域*，因为下一个节点 S'（语句表）仍然需要在函数的作用域内执行。
3. 当当前节点是函数声明节点 D 时，且刚刚从 S'（语句表）退出后，则退出当前作用域，恢复到函数的直接父作用域编号。

注意：该文法不允许在复合语句内声明变量或数组，因此在复合语句内不需要进入新作用域。

1.2.2.2 CFG 表示模型设计

1.2.2.2.1 文件存储模型扩展

显然，现在的 CFG 文法定义经过了语义扩展，需要重新设计文件存储模型。

回顾之前的 CFG 格式：

```
# S' → E
# E → E + T | T
# T → T * F | F
# F → (E) | id
cfg:
  terminals:
  - "id"
  - "+"
  - "*"
  - "("
  - ")"
  non_terminals:
  - "E"
  - "T"
  - "F"
  initial_symbol: "E"
  production_rules:
  - lhs: "E"
    rhs:
    - "E"
    - "+"
    - "T"
  - lhs: "E"
    rhs:
    - "T"
  - lhs: "T"
    rhs:
    - "T"
    - "*"
    - "F"
  - lhs: "T"
    rhs:
    - "F"
  - lhs: "F"
    rhs:
    - "("
    - "E"
```

```
    - ")"
  - lhs: "F"
    rhs:
    - "id"
```

最简单的方案就是对每个产生式标注一个 node_type 属性，表示该产生式对应的节点类型。这样就能在语义分析和中间代码生成时根据节点类型进行处理。

```
  - lhs: "F"
    rhs:
    - "id"
    node_type: "EXPR_VAR" # 表示这是一个变量表达式节点，仅作示例
```

1.2.2.2.2 CFG 模型扩展

还需要最后一块拼图，因为现在的 CFG 模型中只包含产生式的形式，而没有包含语义分析和中间代码生成所需的节点类型信息。为了不破坏已有的依赖关系，另外定义一个结构体，表示每个产生式的语义信息。它能够根据当前表达式从查询出对应的节点类型。显然一个表达式只有一个节点类型

```
namespace cfg_model {
    struct CFG
    {
        cfg_model::symbol start_symbol;
        std::unordered_set<cfg_model::symbol> terminals;
        std::unordered_set<cfg_model::symbol> non_terminals;
        std::unordered_map<cfg_model::symbol, std::unordered_set<std::v
ector<cfg_model::symbol>>> production_rules;
        std::unordered_set<cfg_model::symbol> epsilon_production_symbol
s;
    };
} // namespace cfg_model
// 本质上是个复杂的多级map，表示每个非终结符的产生式列表
struct ProductionInfoMapping {
    std::unordered_map<cfg_model::symbol, std::unordered_map<std::vecto
r<cfg_model::symbol>, std::string>> production_info; // 产生式信息，键为
非终结符，值为一个map，键为产生式右侧符号序列，值为节点类型
    // 提供一个包装好的查询方法，能够应对没找到的情况（报错）
    std::string get_node_type(const cfg_model::symbol& lhs, const std::
vector<cfg_model::symbol>& rhs) const;
};
```

1.2.2.3 AST 树设计

显然 AST 树就是一棵模板类型为<ASTNodeContent, ordered<>>的 tree.hh 树形结构。每个节点的类型都是 ASTNodeContent 的派生类，表示不同类型的节点。模板后一个参数规定了这棵树会保持每个节点的各个子节点的顺序。

1.2.3 架构设计

基本架构：

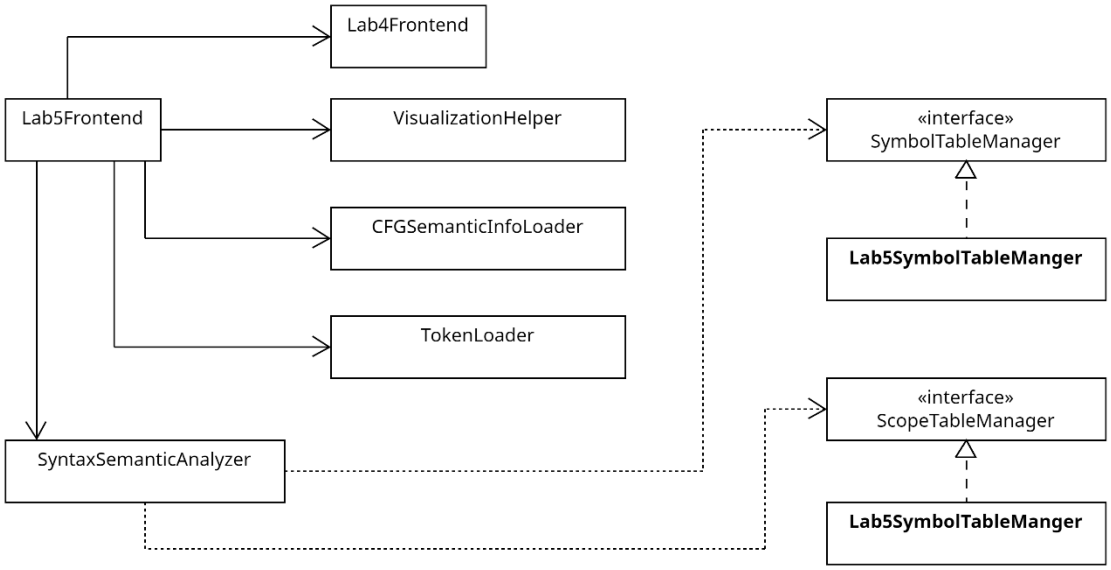

模块依赖关系：

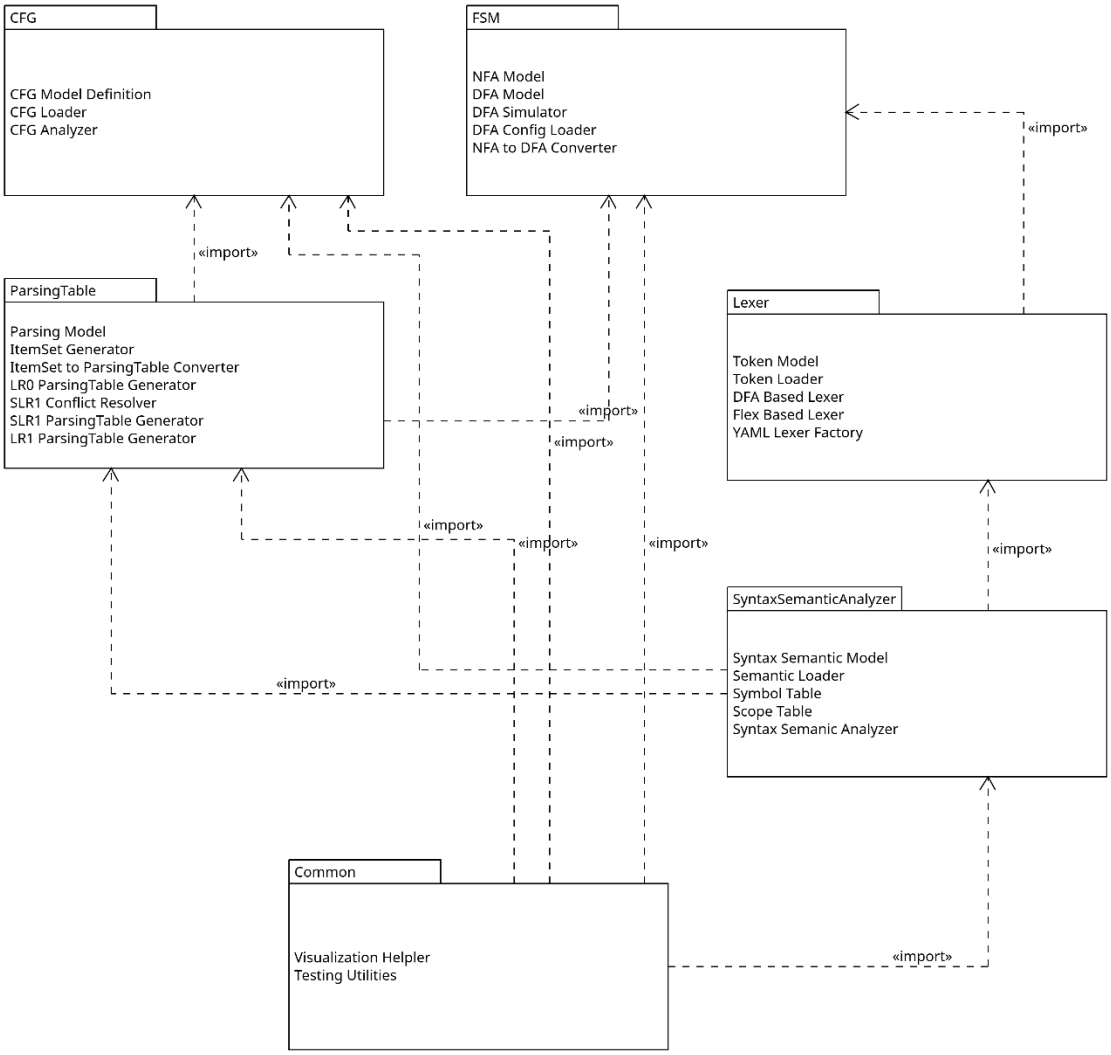

按照单一职责原则分为了几个独立模块：（前几个实验中有的就不介绍了）

1. **TokenLoader**：一个多功能 token 接口/缓冲区。考虑到整合时需要从 Lexer 获取 token，而测试时需要从文件中读取 token，因此设计为一个中间类，提供直接输入 token 流和从文件获取 token 流的功能。而后续分析器只需要从中拿 token 而无需考虑具体的 token 来源。
2. **CFGSemanticInfoLoader**：一个 CFG 语义信息加载器，负责从文件中加载 CFG 的语义信息，包括产生式的节点类型等。它会将这些信息存储在 ProductionInfoMapping 中，以便后续查询。
3. **SymbolTableManager**：符号表管理器，存放上文设计的符号表及相关辅助函数。
4. **ScopeTableManager**：作用域表管理器，存放上文设计的作用域表及相关辅助函数。
5. **SyntaxSemanticAnalyzer**：尽管在编译原理中语法分析和语义分析通常是分开的，但是考虑到该设计语法分析和语义分析非常紧密相关，比如，在语法分

析构建 AST 树的时候同时也要给节点填上 node_type 属性，因此设计了这个连接类。

6. **VisualizationHelper**：可视化助手，在实验三中已经实现了一个可视化 DFA 和 NFA 的工具，利用 Boost Graph 库实现了一个可视化工具。这里同样利用 Boost Graph 库实现可视化 AST 树的功能。理论上应该比可视化图更简单。

1.3 实现细节

备注：由于代码量过大，此处不直接展示实现代码。请在附加的源码中按照上文“模块依赖关系图”对应的源文件中浏览源码。

1.3.1 TokenLoader 实现

TokenLoader 的实现很简单，它只暂存一个 token 流。如果调用了 load_from_file 方发或 load_from_tokens 方法，则会立刻覆盖当前的 token 流。之后可以通过 get_all_tokens 方法获取所有的 token。

对于从文件中加载 token 流的情况，TokenLoader 除了读取 token 外还要检查一下文件是否符合预期的格式。比如每一行都应该符合左括号-类型-逗号和空格-值-右括号的格式，每行有且只能有一个 token 等。

token 流的定义是由实验规定的，如：

(INT, -)

(ID, b)

(SCO, -)

(ID, b)

(ASG, -)

(NUM, 2)

(SCO, -)

其中-表示该 token 没有附加值，比如运算符等。对于有附加值的 token，如数字、标识符等，则会在括号内给出对应的值。

1.3.2 CFGSemanticInfoLoader 实现

CFGSemanticInfoLoader 的实现同样简单，它从文件中加载 CFG 的语义信息，并将其存储在 ProductionInfoMapping 中。它会检查文件格式是否符合预期（例如是否每个产生式都有语义类型），并在加载过程中将每个产生式的节点类型信息存储起来。除此之外，它并不检查语义信息是不是符合预定义的语义规则。

1.3.3 SymbolTableManager 实现

SymbolTableManager 的大部分细节都已经在上文给出了，这里主要描述几个方法实现：

1. addSymbol：添加符号到符号表。首先对 Symbol 进行检查，5 个共有属性缺一不可。然后检查符号表中是否已经存在同名符号，如果存在则抛出语义错误，表示重复声明。最后将符号添加到符号表中。
2. symbolExists：判断符号是否存在。根据符号名和作用域 id 在符号表中查找，如果找到则返回 true，否则返回 false。
3. findSymbolInScope：查找某个作用域内的某个符号。根据符号名和作用域 id 在符号表中查找，如果找到则返回对应的符号对象，否则返回 std::nullopt。
4. getAllSymbolsInScope：获取当前作用域的符号列表。根据作用域 id 在符号表中查找所有符号，并返回一个向量。

1.3.4 ScopeTableManager 实现

1. reset：重置作用域表，清空作用域栈和子作用域表，设置作用域 id 计数器为 0，并将当前作用域设置为 0。
2. enterNewScope：进入新作用域。首先将当前作用域编号入栈，然后递增作用域 id 计数器，设置新的作用域编号，并更新子作用域表和父作用域表。
3. exitCurrentScope：退出当前作用域。首先将当前作用域编号出栈，然后恢复到上一个作用域，并更新子作用域表和父作用域表。
4. getDirectChildScopes：查询直接子作用域。根据父作用域编号在子作用域表中查找直接子作用域编号列表。如果没有查到，则返回一个空向量。
5. getDirectParentScope：查询直接父作用域。根据子作用域编号在父作用域表中查找直接父作用域编号。如果没有查到，则返回-1。
6. getCurrentScope：获取当前作用域编号，也就是栈顶的作用域编号。

1.3.5 SyntaxSemanticAnalyzer 实现

这是整个程序的核心。首先介绍其大致工作过程：

1. 输入检查，主要是检查两个方面：token 流的类别是不是在 CFG 里面都定义了，以及 CFG 的语义信息是不是完整且符合预定义的语义规则。
2. SLR(1)语法分析，使用 SLR(1)分析表对 token 流进行语法分析，构建 AST 树。每个节点的 node_type 属性会根据 CFG 的语义信息进行设置。
3. 语义分析，遍历 AST 树，对每个节点执行语义动作函数。这个过程会检查符号表和作用域表，进行必要的语义检查，并生成中间代码。

1.3.5.1 输入检查

在 SLR1 分析表的数据模型中已经附带了一个 Symbol 列表，包含所有的 CFG 符号。

1. 生成一个字符串集合，是 CFG 中所有终结符的集合。
2. 遍历 TokenLoader 中的 token 流，检查每个 token 的类型是否在终结符集合中。如果有不在集合中的类型，则抛出错误，表示输入的 token 流中包含未定义的终结符。
3. 检查 CFG 的语义信息是否完整。对 ProductionInfoMapping 中的每个产生式，检查其节点类型是否在预定义的语义规则中。如果有不符合预定义语义规则的节点类型，则抛出错误，表示 CFG 的语义信息不完整或不符合预定义语义规则。

1.3.5.2 语法分析

现在已经可以确认输入的 token 流和 CFG 的语义信息都是正确的，开始进行 SLR(1) 语法分析。

首先，语法分析需要接收几个基本信息：

1. LR 分析表（slr_table）：一个预先产生的 LR 分析表，包含状态转移和归约规则。
2. AST 语义信息映射（production_info_mapping）：一个 ProductionInfoMapping 对象，用于查询每个产生式的节点类型。
3. 要分析的 Token 流（token_stream）：一个 token 向量，表示要分析的 token 流。

此外，语法分析还需要调用一些辅助属性：

1. 当前符号栈（symbol_stack）：一个向量，表示当前的符号栈，用于存储当前状态和符号。
2. 当前状态栈（state_stack）：一个向量，表示当前的状态栈，用于存储当前状态。
3. 当前 AST 子树栈（ast_tree_stack）：一个向量，表示当前的 AST 子树栈，用于存储当前状态下的所有 AST 子树。该栈和符号栈完全同步，只是使用 AST 数据类型。（实际上这两个栈可以合并，此处为了算法清晰还是保留符号栈作为辅助，以防万一有可视化或者调试需要）
4. 当前 AST 树（ast_tree）：一个 st_tree 对象，表示当前的 AST 树。
5. 当前 token 索引（current_token_index）：一个整数，表示当前正在处理的 token 在 token 流中的索引。

语法分析的工作过程如下：

1. 初始化符号栈/状态栈/AST 子树栈为空，AST 树为空，当前 token 索引为 0。
2. 从 SLR(1)分析表中获取起始状态作为当前状态，将其添加到状态栈中。

3. 从 SLR(1)分析表的符号列表中找到 END 结束符号，将其添加到 Token 流的末尾。其名称为结束符号的名称，值为空。
4. 开始循环处理 token 流，直到所有 token 都被处理完毕。
    - 如果接下来已经没有 token 可处理，则抛出错误，表示语法分析失败。
    - 获取当前 token 的类型和值。
    - 根据当前状态和当前 token 的类型，从 SLR(1)分析表中找到对应单元格，获取其 Action。
    - 如果 Action 的类型是 empty，则抛出错误，表示语法分析失败。
    - 如果 Action 的类型是 shift，操作三个栈
        - 在 SLR(1)分析表找到 Token 对应的 Symbol，并将其添加到符号栈中。
        - 将 Action 中的状态添加到状态栈中。
        - 创建一个新的 st_tree，其根节点就是唯一节点，其 node_type 为当前 token 的类型，如果有 value 就是 token 的 value，并将其添加到 AST 子树栈中。
        - 将当前 token 索引递增 1，准备处理下一个 token。
    - 如果 Action 的类型是 reduce，则先从 Action 中提取预先存储的产生式信息，然后在 production_info_mapping 中查询该产生式的节点类型。接着操作三个栈
        - 从符号栈中弹出产生式右侧的符号数量个符号，然后将左侧的符号添加到符号栈中。
        - 从状态栈中弹出产生式右侧的符号数量个状态，然后根据 Action 中的 goto 信息，将左侧符号对应的状态添加到状态栈中。
        - 从 AST 子树栈中弹出产生式右侧的子树数量个子树，然后创建一个新的 st_tree，其根节点的 node_type 为查询到的产生式节点类型，*然后将弹出的子树按照产生式右侧的顺序添加到根节点的子节点列表中（所以要将弹出的子树存放在向量内，然后把向量从后往前遍历）*。接着对根节点执行 subnode_takein 方法（此时无需担心子节点属性为空，因为保存的都是节点指针），将子树添加到根节点的子节点列表中。最后将该根节点作为一个新的子树压入 AST 子树栈。
        - 将当前 token 索引不变，继续处理下一个 token。

- 如果 Action 的类型是 accept，则表示语法分析成功，此时 AST 子树栈中应当恰好有一个子树，即为最终的 AST 树。将该子树的根节点设置为 AST 树的根节点，并结束语法分析。

1.3.5.3 语义分析

语义分析就是对 AST 树的一次先序遍历。遍历过程中对每个节点执行其语义动作函数，并传入当前作用域编号、符号表和作用域表。

语义分析的工作过程如下：

1. 初始化作用域表和符号表，重置作用域表，设置当前作用域为 0。
2. 从 AST 树的根节点开始，进行先序遍历。
3. 对每个节点执行以下操作：
    - 在进入节点前，按作用域表管理规则处理作用域（如上文）
    - 在即将退出节点时，调用 semantic_action 方法执行语义动作。
    - 在退出节点后，按作用域表管理规则处理作用域（如上文）
4. 如果在遍历过程中遇到语义错误，则抛出异常，表示语义分析失败。
5. 如果整个遍历完成且没有遇到语义错误，则表示语义分析成功。

2 选做部分

实现了两个额外功能：

1. 使用 LR1 分析器替换 SLR1 分析器（SLR1 分析器依然可以在语法/语义分析中使用），并且在冲突无法解决时应用手动策略
2. 编译优化：支持表达式类型中的常量折叠

2.1 可设置手动策略的 LR1 分析器

实现了经典的 LR1 分析器，直接派生实验中定义的 LR 分析器接口。因为 LR1 分析是直接产生 Closure 和 Goto 的，因此该分析器输出 DFA 而无法输出 NFA（没有构建 NFA 的中间过程）。声明如下：

```
class LR1ParsingTableGenerator : public LRParsingTableGenerator
{
public:
    LR1ParsingTableGenerator() = default;
    ~LR1ParsingTableGenerator() override = default;
    lr_parsing_model::LRParsingTable generate_parsing_table(const cfg_m
odel::CFG &cfg) override;
```

```
    lr_parsing_model::ItemSet generate_item_set(const cfg_model::CFG &c
fg) override;
    // the LR1 table generation is completely DFA-
based, thus not providing NFA generation
    lr_parsing_model::LR1ItemSetDFAGenerationResult generate_item_set_d
fa(const cfg_model::CFG &cfg);
private:
    LR1ItemPool pool_; // 新增：LR1Item 对象池
};
namespace lr1_parsing_table_generator_helper
{
    // the strategy for dealing with conflicts that cannot be resolved
by the LR(1) parsing table generator
    enum class LR1ConflictResolutionStrategy
    {
        SHIFT_OVER_REDUCE, // shift over reduce
        REDUCE_OVER_SHIFT, // reduce over shift
    };
    // generate LR(1) parsing table to item set mapping
    lr_parsing_model::ItemSetParsingTableMapping generate_item_set_pars
ing_table_mapping(
        const lr_parsing_model::LRParsingTable &parsing_table,
        const lr_parsing_model::ItemSet &item_set,
        const lr_parsing_model::ItemSetDFAMapping &item_set_dfa_mapping
    );
    // resolve conflicts in the LR(1) parsing table
    lr_parsing_model::LRParsingTable resolve_conflicts(
        const lr_parsing_model::LRParsingTable &parsing_table_to_be_res
olved,
        const lr_parsing_model::ItemSetParsingTableMapping &item_set_pa
rsing_table_mapping,
        const LR1ConflictResolutionStrategy &conflict_resolution_strate
gy = LR1ConflictResolutionStrategy::SHIFT_OVER_REDUCE
    );

    // helper functions for LR(1) parsing table generation
    // generate a blank LR(1) item set from an LR(0) item set
    lr_parsing_model::ItemSet generate_blank_lr1_item_set(const lr_pars
ing_model::ItemSet &item_set, LR1ItemPool& pool);
    // generate a set of LR(1) items from an LR(0) item and their looka
head symbols
    std::unordered_set<std::shared_ptr<lr_parsing_model::LR1Item>> grow
_closure(
```

```
        const std::unordered_set<std::shared_ptr<lr_parsing_model::LR1Item>> &initial_items,
        const lr_parsing_model::ItemSet &reference_lr0_item_set,
        const cfg_model::CFG &cfg,
        const cfg_model::FirstSet &first_set,
        const cfg_model::FollowSet &follow_set,
        LR1ItemPool& pool);
    // generate the initial closure items from an existing closure by moving in one symbol
    std::unordered_set<std::shared_ptr<lr_parsing_model::LR1Item>> generate_initial_closure(
        const std::unordered_set<std::shared_ptr<lr_parsing_model::LR1Item>> &closure_items,
        const lr_parsing_model::ItemSet &reference_lr0_item_set,
        const cfg_model::symbol &next_symbol,
        const cfg_model::CFG &cfg,
        const cfg_model::FirstSet &first_set,
        const cfg_model::FollowSet &follow_set,
        LR1ItemPool& pool);
    // generate a unique DFA name string for an LR(1) closure set
    std::string generate_lr1_closure_name(const std::unordered_set<std::shared_ptr<lr_parsing_model::LR1Item>> &closure_items);
}
```

其中 grow_closure 和 generate_initial_closure 分别对应经典算法中的 CLOSURE 和 GOTO 函数。

注意实验文法的语句部分：

```
S -> d = E | d[E] = E | if (B) S | if (B) S else S | while (B) S | return E | {S'} | d(R') # 语句
```

这里出现了典型的**悬挂 ELSE** 问题。属于文法本身的二义性，无法通过 SLR1 或者 LR1 分析解决。处理这个问题可以通过改写文法完成，但是这会导致可读性下降和需要重写语义动作函数。查阅资料后发现现代语法分析工具可以通过手动设置移进优先/规约优先来解决类似问题，因此在 LR1 分析器中也添加了类似的功能。

```
    // the strategy for dealing with conflicts that cannot be resolved by the LR(1) parsing table generator
    enum class LR1ConflictResolutionStrategy
    {
        SHIFT_OVER_REDUCE, // shift over reduce
        REDUCE_OVER_SHIFT, // reduce over shift
    };
```

该 LR1 分析器可以生成复杂的分析表并解决冲突。例如在实验文法中，产生的 DFA 大约有 300 余个状态**（编译运行单元测试 lab5/build/test_all 即可获得这个 DFA：lab5/build/integration_final_semantic_dfa_lr1.svg 和对应的分析表：**

lab5/build/integration_final_semantic_parsing_table_lr1.md）。实验证明可以通过其生成的分析表进行正确的语法分析和语义分析。

2.2 在语义分析时进行表达式常量折叠

其具体过程已经在实验部分详述。如果 AST 节点类型是 EXPR_ARITH_NOCONST：

- 检查左右侧表达式结果类型是否一致，如果不一致则抛出语义错误，表示类型不匹配。
- 检查左右侧表达式的计算结果数据类型是否为整数或浮点数，如果不是则抛出语义错误，因为没法计算 void 类型的表达式。
- 如果左右侧表达式都是常量，则进行常量折叠，计算结果并将 data_type 和 value 设置到当前节点的属性中。同时，修改当前节点的 node_type 为 EXPR_CONST。
- 如果有任意一个表达式不是常量，则将 data_type 设置为左右侧表达式的计算结果数据类型，并将 node_type 保持为 EXPR_ARITH_NOCONST。

常量折叠的效果会在下文中展示。

3 实验结果

3.1 文法二义性消解

早期测试发现，实验给出的文法中存在一些固有的二义性，这些歧义无法通过 SLR1 乃至 LR1 分析进行消除，此时需要对文法在保持设计的同时进行二义性消除。

首先是文法的语句部分：

```
S -> d = E | d[E] = E | if (B) S | if (B) S else S | while (B) S | return E | {S'} | d(R') # 语句
```

这个悬挂 ELSE 问题已经通过在 LR1 分析器中设置手动策略解决了。

其次是算术表达式中加法和乘法没有显示指定优先级：

```
E -> num | flo | d | d[E] | E + E | E * E | (E) | d(R') # 常规算数表达式
```

解决方法是引入一些中间状态，确保乘法优先和乘法的左结合性。

```
E -> E ADD E_MUL | E_MUL
E_MUL -> E_MUL MUL E_ATOMIC | E_ATOMIC
E_ATOMIC -> NUM | FLO | ID | ID LBK E RBK  |  LPA E RPA  | ID LPA R' RPA
```

其中 E_MUL 和 E_ATOMIC 作为临时状态，其语义动作只需要向上传递子节点的信息即可。

最后一个二义性问题相对复杂，考虑实验文法的子片段：

```
S' -> Func
Func -> id ( R' )
R' -> ε | R' R ,
R -> E | id ( )
E -> int | Func
```

这个二义性来自于类似下面这种情况，如果存在这样一个函数调用 add(1,rand())，那么其中的 Rand 可以被归类为函数返回值结果（R -> E），也可以被归类为函数指针调用（R -> id ( )），**而具体是哪一类需要查看 add 函数的参数列表定义——这要到语义分析结束才能实现。**

因此，决定去掉产生式 R -> id ( )。通过合理设计中间代码生成器，可以保证这样做不会影响文法的功能，因为：

1. 当进行中间代码生成时，所有的函数及其参数列表都已经确定了
2. 通过访问 E 表达式的子节点，仍然可以确定函数的变量名

因此可以在中间代码生成时通过访问符号表来找到 rand()到底应该被解释为指针还是函数返回值结果。如果是指针也依然可以通过 E 节点的子节点找到其符号定义和相关信息。

3.2 语法语义分析器测试

设计了 56 个测试，从中选取两个有代表性的集成测试进行展示。

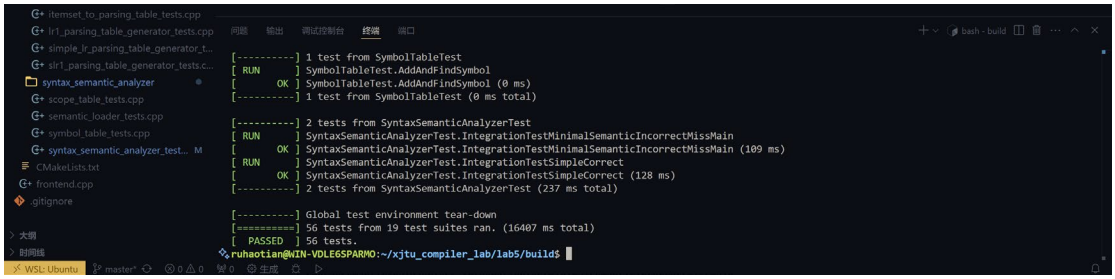

首先测试一个简单程序 int b; b = 2，其对应的 Token 列表如下：

(INT, -)

(ID, b)

(SCO, -)

(ID, b)

(ASG, -)

(NUM, 2)

这个程序有如下特点：

- 语法是正确的，因此应该通过语法分析
- 语义是错误的，因为没有定义 main 函数，因此无法通过语义分析。

测试程序如下：

```
// integration test for syntax semantic analyzer, testing a minimal syn
tax correct but semantic incorrect case: missing main function
TEST_F(SyntaxSemanticAnalyzerTest, IntegrationTestMinimalSemanticIncorr
ectMissMain)
{
    // Create a token loader and load tokens from a file
    TokenLoader token_loader;
    std::string token_file_path = test_data_dir + "minimal_semantic_inc
orrect_missMain_tokens.txt";
    token_loader.load_from_file(token_file_path);
    // Load semantic information
    std::string semantic_info_file = cfg_semantic_file;
    syntax_semantic_model::ProductionInfoMapping production_info_mappin
g = load_semantic_info(semantic_info_file, cfg);
    // Create an instance of SyntaxSemanticAnalyzer
    SyntaxSemanticAnalyzer analyzer;
    // Perform analysis
    analyzer.prepair_new_analysis(lr1_parsing_table, production_info_ma
pping, token_loader.get_tokens());
    auto ast_tree = analyzer.get_blank_ast_tree();
    // Check if the AST tree is not empty
    ASSERT_FALSE(ast_tree.empty());
    // generate AST tree dot file
    visualization_helper::generate_ast_tree_dot_file(ast_tree, "integra
tion_minimal_semantic_incorrect_missMain_ast_tree_blank", true);
    // perform syntax and semantic analysis, this should throw an excep
tion due to semantic error
    try {
        syntax_semantic_analyzer::analysis_result result = analyzer.ana
lyze_syntax_semantics(lr1_parsing_table, production_info_mapping, token
_loader.get_tokens());
        FAIL() << "Expected a semantic error to be thrown, but none was
 thrown.";
    } catch (const std::runtime_error& e) {
        // Check if the exception message contains the expected semanti
c error
        ASSERT_TRUE(std::string(e.what()).find("Main function not found
") != std::string::npos)
            << "Unexpected exception message: " << e.what();
        spdlog::info("Caught expected semantic error: {}", e.what());
```

```
    }
}
```

可见其应该能够正常输出语法分析后产生的空 AST 树，并在语义分析阶段报错。上述实验结果表明测试可以正常通过。查看产生的空 AST 树：

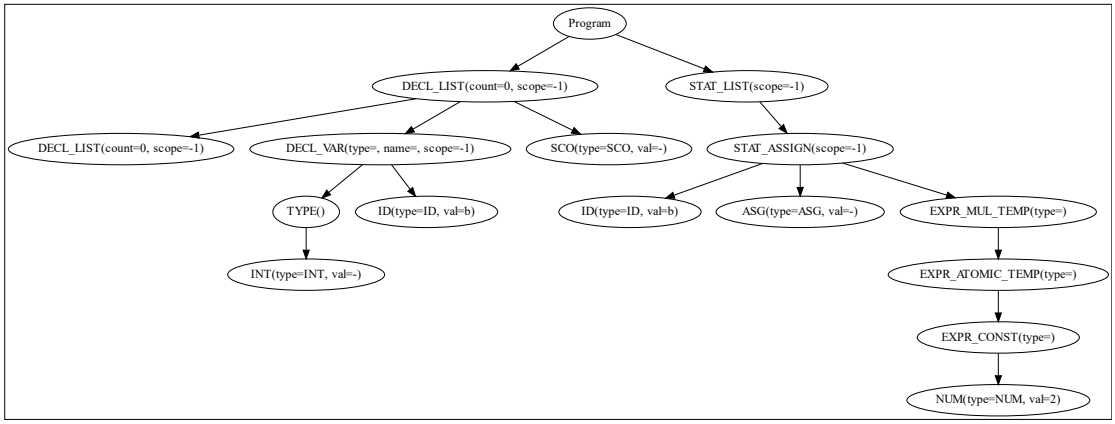

可见语法分析是正确的。请注意因为还没有进行语义分析所以树中各个属性的值为空。

查看测试脚本输出的日志，可见在语义分析中执行 Program 节点语义动作的时候发现没有 main 函数，因此报错并退出：

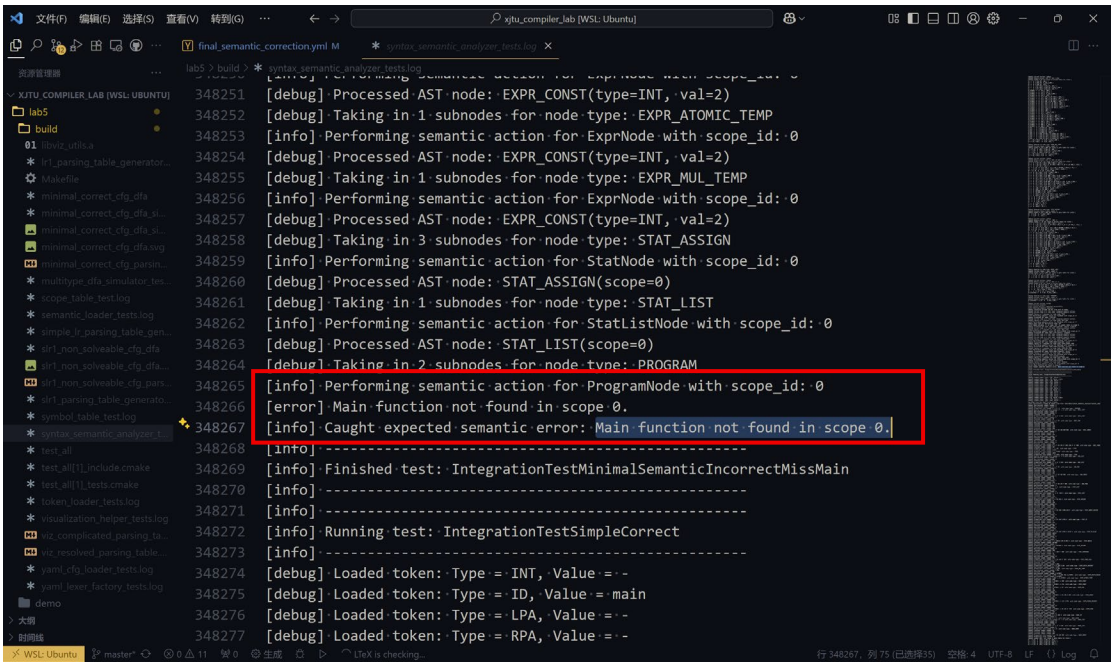

第二个测试是下一个实验实验六 PPT 中给出的示例程序：

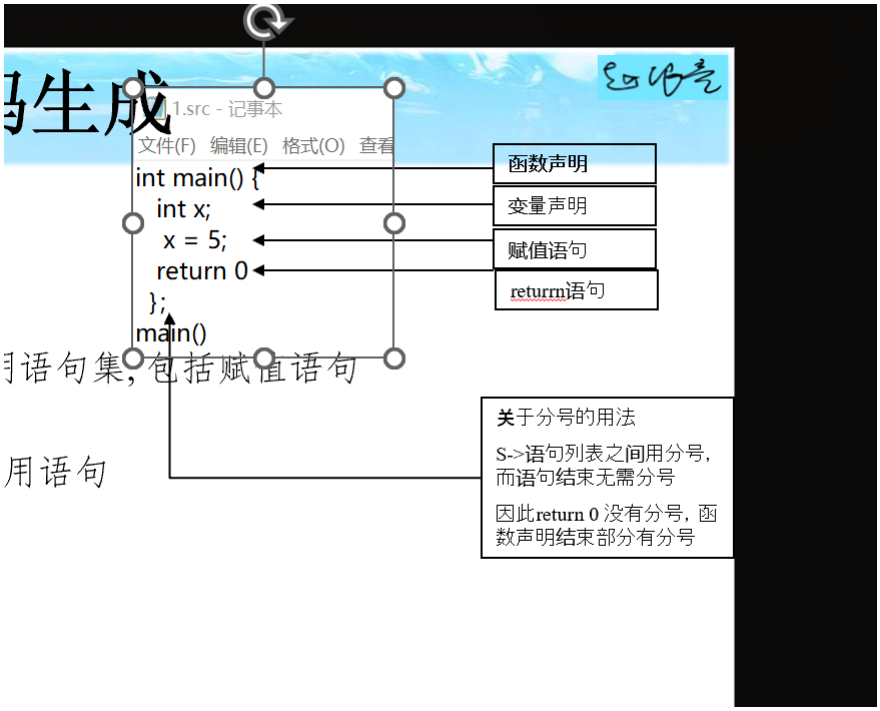

其语义和语法都是正确的，对应的 Token 流如下：

(INT, -)

(ID, main)

(LPA, -)

(RPA, -)

(LBR, -)

(INT, -)

(ID, x)

(SCO, -)

(ID, x)

(ASG, -)

(NUM, 5)

(SCO, -)

(RETURN, -)

(NUM, 0)

(RBR, -)

(SCO, -)

(ID, main)

(LPA, -)

(RPA, -)

测试脚本如下：

```
// integration test for syntax semantic analyzer, testing a simple corr
ect case
TEST_F(SyntaxSemanticAnalyzerTest, IntegrationTestSimpleCorrect)
{
    // Create a token loader and load tokens from a file
    TokenLoader token_loader;
    std::string token_file_path = test_data_dir + "simple_correct_token
s.txt";
    token_loader.load_from_file(token_file_path);
    // Load semantic information
    std::string semantic_info_file = cfg_semantic_file;
    syntax_semantic_model::ProductionInfoMapping production_info_mappin
g = load_semantic_info(semantic_info_file, cfg);
    // Create an instance of SyntaxSemanticAnalyzer
    SyntaxSemanticAnalyzer analyzer;
    // Perform analysis
    analyzer.prepair_new_analysis(lr1_parsing_table, production_info_ma
pping, token_loader.get_tokens());
    auto ast_tree = analyzer.get_blank_ast_tree();
    // Check if the AST tree is not empty
    ASSERT_FALSE(ast_tree.empty());
    // generate AST tree dot file
    visualization_helper::generate_ast_tree_dot_file(ast_tree, "integra
tion_simple_correct_ast_tree_blank", true);
    // perform syntax and semantic analysis
    syntax_semantic_analyzer::analysis_result result = analyzer.analyze
_syntax_semantics(lr1_parsing_table, production_info_mapping, token_loa
der.get_tokens());
    // Check if the result contains a valid AST tree
    ASSERT_FALSE(result.ast_tree.empty());
    // save the AST tree to a file
    visualization_helper::generate_ast_tree_dot_file(result.ast_tree, "
integration_simple_correct_ast_tree_result", true);
    // save the symbol table to a file
    visualization_helper::pretty_print_symbol_table(result.symbol_table
, true, "integration_simple_correct_symbol_table.md");
}
```

测试可以正常通过，并且输出：

1. 经过语法分析的空 AST 树
2. 进一步经过语义分析的完整 AST 树
3. 符号表

首先检查空 AST 树的正确性：

该图为 SVG 矢量图可无限放大

检查经过语义分析的 AST 树，可见各项属性都已经正确填充：

最后查看生成的符号表：

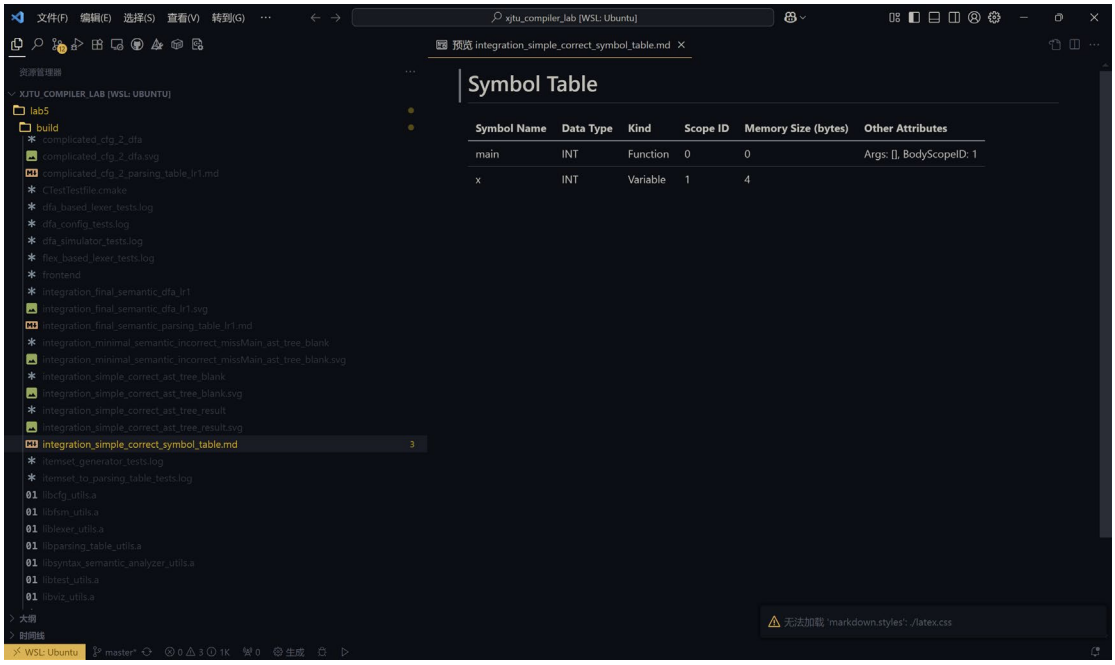

可见 main 函数的作用域为 0，其子作用域为 1，x 变量被分配到了作用域 1 中。